题库扩容计划书

一、目标

从 洛谷、Codeforces、LeetCode 力扣 三个主流平台系统性采集 ⩾1800 道高质量算法题，经过去重、翻译、标签映射、标准化后，导入 XMUOJ 题库。同时为两个大创项目（算法演武场 & AI算法领航员）提供数据基础。

二、采集范围

平台	采集方式	目标数量	采集范围
洛谷	基于开源爬虫改造	⩾1000题	P1000 – P4000 区间的高质量题目（主题库 + 入门与面试题库）
Codeforces	官方开放 API	⩾500题	Rating 800 – 2400，覆盖 Div1 – Div4 全难度段
LeetCode 力扣	基于开源爬虫改造	⩾300题	Hot 100 + 剑指 Offer + 经典面试题 + 周赛题目

三、推荐开源项目（不用从零写）

3.1 洛谷

项目	地址	语言	说明
python_papapa_luogu	github.com/Andy-boy123/python_papapa_luogu	Python	最完整 难度/算 来源/标 编号筛

项目	地址	语言	说明
			带 Tkin GUI，反爬（UA、随 休眠）
Luogu-Problems	github.com/OldSkyGod/Luogu-Problems	PHP	直接爬 库+入门 试题库 出 Marko
LuoguCrawler	github.com/himself65/LuoguCrawler ⭐ 41	Python	通用爬 架，结 参考
luogu topic	github.com/topics/luogu	—	90+ 个 相关仓 可按星

推荐方案：以 `python_papapa_luogu` 为基础改造，去掉 GUI，增加批量导出为统一 JSON 格式的功能。

3.2 Codeforces

Codeforces 有**官方开放** REST API，完全不需要爬虫。

接口	地址	说明
题目列表	`https://codeforces.com/api/problemset.problems`	返回所有题目 + 标签（tags）+ 难度（rating）
题目统计	`https://codeforces.com/api/problemset.problems?tags=dp`	按标签筛选
用户提交	`https://codeforces.com/api/user.status?handle={handle}`	按用户查提交记录

推荐方案：直接调 API，写一个 Python 脚本遍历 tags 拉取全量题目，转化为统一 JSON 格式。零反爬压力，完全合规。

3.3 LeetCode 力扣

项目	地址	语言	说明
Leetcode-problem-scraper	github.com/kaushik-bhat/Leetcode-problem-scraper	Python	两步式：API拿元数据 → GraphQL拿详情，输出干净JSON，过滤premium题目
coding-platform-crawler	pypi: coding-platform-crawler	Python	pip安装，支持批量下载，多格式输出（Python/MD/JSON），89%测试覆盖率
LC-CF-problem-Scrapping	github.com/delta-mohit/LC-CF-problem-Scrapping	Python	Selenium方案，一次爬LC+CF两个平台

推荐方案：以 `kaushik-bhat/Leetcode-problem-scraper` 为基础，改为中国站 `leetcode.cn` 的 GraphQL 端点，添加中文题目采集。

3.4 跨平台参考

项目	地址	语言	说明
ALGO	github.com/zkx06111/ALGO	Python	学术项目，已采集CF+LC题库+测试数据
cp-api	npm: @ronits2407/cp-api	TypeScript	统一SDK，支持CF/LC/AtCoder/CodeChef

---

四、采集技术方案

4.1 洛谷爬虫改造要点

基于 `python_papapa_luogu` 改造：

```
原项目结构：
├─ main.py           # Tkinter GUI 主界面
├─ luogu_spider.py    # 爬虫核心逻辑
├─ decrypt.py         # 标签/难度解码
└─ output/            # CSV 输出

改造后：
```

```
├─ crawl_luogu.py     # 命令行批量爬取（去掉GUI）
├─ luogu_standardize.py  # 输出统一JSON格式
└─ output/luogu_problems.json
```

关键技术点： - 洛谷题目列表 API：`https://www.luogu.com.cn/problem/list?page={}&type={}&tag={}&difficulty={}` - 题目详情 API：`https://www.luogu.com.cn/problem/{pid}?_contentOnly=1` - 反爬应对：随机 User-Agent、请求间隔 ⩾3秒、Cookie 模拟登录态 - 标签解码：`_lfe/tags` 端点返回的 tag ID 映射表

4.2 Codeforces API 采集脚本

```python
# 伪代码
import requests

def fetch_all_cf_problems():
    resp =
        requests.get("https://codeforces.com/api/problemset.problems")
    data = resp.json()
    problems = data["result"]["problems"]
    stats = data["result"]["problemStatistics"]

    for p, s in zip(problems, stats):
        problem = {
            "source_platform": "codeforces",
            "source_id": f"{p['contestId']}{p['index']}",
            "title": p["name"],
            "tags": p["tags"],
            "rating": p.get("rating", 0),
            "solved_count": s.get("solvedCount", 0),
            "time_limit_ms": 1000,  # CF 默认
            "memory_limit_mb": 256,
        }
        yield problem
```

4.3 LeetCode 爬虫改造要点

基于 `kaushik-bhat/Leetcode-problem-scraper` 改造：

- 改用 `leetcode.cn` 的 GraphQL 端点（`https://leetcode.cn/graphql`）
- 需要携带登录后的 Cookie（用环境变量配置）
- GraphQL 查询示例：

```
query problemsetQuestionList($categorySlug: String, $limit: Int, $skip:
        Int, $filters: QuestionListFilterInput) {
  problemsetQuestionList(categorySlug: $categorySlug, limit: $limit,
        skip: $skip, filters: $filters) {
```

```
    total
    questions {
      title
      titleSlug
      difficulty
      topicTags { name slug }
      translatedTitle  # 中文标题
    }
  }
}
```

- 题目详情通过 `questionData(titleSlug: $slug)` 查询

五、数据标准化

5.1 统一中间格式

所有采集到的题目统一转为以下 JSON 结构：

```
{
  "source_platform": "luogu",
  "source_id": "P1001",
  "source_url": "https://www.luogu.com.cn/problem/P1001",
  "title": "A+B Problem",
  "title_cn": "A+B 问题",
  "description_html": "<p>输入两个整数a,b，输出它们的和。</p>",
  "input_description_html": "两个整数，空格分隔",
  "output_description_html": "一个整数",
  "difficulty": 1,
  "difficulty_source": "luogu_difficulty",
  "cf_rating": null,
  "tags_original": ["入门", "模拟"],
  "tags_unified": ["模拟", "基本输入输出"],
  "samples": [{"input": "1 2", "output": "3"}],
  "time_limit_ms": 1000,
  "memory_limit_mb": 128,
  "has_solution": true,
  "collected_at": "2026-08-15T10:00:00Z"
}
```

5.2 标签映射表

将三个平台的标签体系统一映射为 XMUOJ 知识体系的 80+ 知识点分类。

洛谷标签	Codeforces Tag	LeetCode标签	统一知识点
动态规划,dp	dp	动态规划	DP
深度优先搜索,dfs	dfs and similar	深度优先搜索	DFS
最短路	shortest paths	—	图论 · 最短路径
线段树	data structures	线段树	数据结构 · 线段树
贪心	greedy	贪心	贪心算法
二分	binary search	二分查找	二分查找
数学,math	math	数学	数学
字符串	strings	字符串	字符串
图论	graphs	图	图论
树	trees	树	数据结构 · 树
排序	sortings	排序	排序
并查集	dsu	并查集	数据结构 · 并查集
数论	number theory	数学 · 数论	数学 · 数论
组合数学	combinatorics	数学 · 组合	数学 · 组合
…	…	…	…

完整映射表 ≥200 条，用 CSV 维护，方便后续增补。

5.3 难度归一化

三个平台难度体系不同，需要归一化：

统一难度	洛谷	Codeforces Rating	LeetCode
1（入门）	入门	≤1000	Easy
2（基础）	普及−	1000-1300	Easy-Medium
3（进阶）	普及/提高	1300-1700	Medium
4（挑战）	提高+	1700-2100	Medium-Hard
5（竞赛）	省选/NOI	2100+	Hard

5.4 去重

- 基于标题的编辑距离（Levenshtein ≤3 且长度相似 → 可疑重复）
- 同一题在不同平台出现时（如”两数之和”在洛谷和力扣都有），保留所有版本但标注 `duplicate_of` 字段
- 人工抽检 5%

六、导入 XMUOJ

6.1 导入流程

```
标准化JSON → FPS格式转换 → Django manage.py import → 审核发布
```

- XMUOJ 已支持 FPS（Free Problem Set）XML 格式批量导入
- 编写 `json_to_fps.py` 转换脚本
- Django Management Command：`python manage.py import_fps --file problems.fps`
- 导入时自动关联 `tags_unified` 到 XMUOJ 的 `ProblemTag` 模型
- 保留来源平台链接在 `source` 字段

6.2 测试数据

- 不导入原平台的测试数据（版权限制 + 平台使用协议）
- 使用 XMUOJ 的 JudgeServer 能力，为采集到的题目手动构造测试数据
- 优先级：先为 ⩾100 道高频题构造测试数据，其余逐步补充
- 未来可考虑用程序自动生成边界测试数据

七、合规与版权

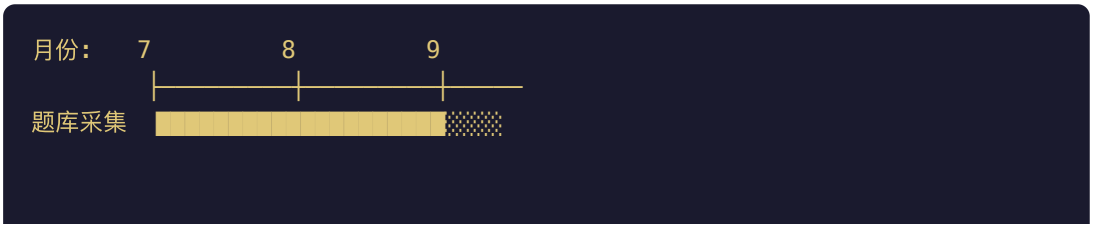
事项	处理
洛谷	仅采集公开题目。标注”题目来源：洛谷 Pxxxx”，保留原始链接。遵守洛谷用户协议
Codeforces	题目版权归 Codeforces 及作者。标注来源链接。CF 允许 educational use

事项	处理
LeetCode	仅采集中国站免费题目（非 premium）。仅用于教学目的，标注来源
测试数据	不采集原平台测试数据，自行构造
题解	采集公开题解时标注原作者和链接
免责声明	在导入页面注明题目来源，非 XMUOJ 原创

八、时间与团队

阶段	时长	人数	工作内容
1. 环境搭建 + 开源项目评估	1周	1人	克隆推荐项目、本地跑通、评估改造工作量
2. 洛谷爬虫改造	2周	1人	基于 `python_papapa_luogu` 改造，增量爬取≥1000题
3. CF API 采集	1周	1人	调 API 拉取≥500题（可在洛谷爬虫同时进行）
4. LeetCode 爬虫改造	2周	1人	基于 `Leetcode-problem-scraper` 改造为中国站
5. 标签映射 + 难度归一化	1周	1人	建立≥200条映射表，难度统一
6. 去重 + 质量抽检	1周	1人	去重算法 + 人工抽检5%
7. FPS 导入 XMUOJ	1周	1人	JSON→FPS→Django import，标签关联
合计	9周	1-2人	

与两个大创项目的时间衔接





九、交付物清单

- [ ] 洛谷/CF/LeetCode 三套采集脚本（可重复运行、支持增量更新）
- [ ] 标准化中间文件：`luogu_problems.json` / `cf_problems.json` / `leetcode_problems.json`
- [ ] 标签映射表 CSV（≥200条）
- [ ] `json_to_fps.py` 转换脚本
- [ ] Django Management Command：`import_collected_problems`
- [ ] 导入后的 XMUOJ 线上题库（≥1800 道可做题）
- [ ] 采集与导入操作手册（供后续维护）